

实验 2. 隐马尔科夫模型实践

MF1733014, 高少华, cuggsh@163.com

2018 年 4 月 3 日

综述

隐马尔科夫模型 (Hidden Markov Model, HMM) 是一种有向图模型, 它用来描述一个含有隐含未知参数的马尔可夫过程, 在语音识别, 自然语言处理等领域有广泛的应用。以下对该模型的简要说明, 参考自文献 [?] 的相关章节。

图 1: 隐马尔可夫模型的图结构

如图 1 所示, 在隐马尔可夫模型中, 存在两组变量, 其中 $\{y_1, y_2, \dots, y_n\}$ 为状态变量, 通常是隐藏的, 不可被观测的, 也称作隐变量。隐变量的取值通常是有 N 个可能取值的离散空间 $S = \{s_1, s_2, \dots, s_N\}$ 。另一组 $\{x_1, x_2, \dots, x_n\}$ 为观测变量, 可被直接观测到, 其取值可以是离散的, 也可以是连续的, 这里假设其取值也是一个离散空间 $O = \{o_1, o_2, \dots, o_M\}$ 。在任意时刻, 观测变量的取值仅依赖于隐变量, 即 x_t 由 y_t 确定, 与其他的隐变量及观测变量无关。同时, t 时刻的隐变量 y_t 仅依赖于 $t-1$ 时刻的隐变量 y_{t-1} , 即系统下一时刻的状态只与当前时刻的状态有关。则可得所有变量的联合概率分布为

$$P(x_1, y_1, \dots, x_n, y_n) = P(y_1)P(x_1|y_1) \prod_{i=2}^n P(y_i|y_{i-1})P(x_i|y_i) \quad (1)$$

确定一个隐马尔可夫模型还需以下三组参数:

- 状态转移矩阵: 模型在各个状态间转换的概率, 记作 $A = [a_{ij}]_{N \times N}$, 其中 a_{ij} 表示在任意时刻从状态 s_i 转换到状态 s_j 的概率。
- 发射矩阵: 模型在当前状态获得各个观测值的概率, 记作 $B = [b_{ij}]_{N \times M}$, 其中 b_{ij} 表示在任意时刻从状态 s_i 获取观测值 o_j 的概率。
- 初始分布: 模型在初始时刻各状态出现的概率, 记作 $\pi = (\pi_1, \pi_2, \dots, \pi_N)$, 其中 π_i 表示模型在初始时刻, 状态为 s_i 的概率。

隐马尔可夫模型有三个基本问题:

- 已知模型参数 $\lambda = [A, B, \pi]$ 和某一特定的观测序列 $\{x_1, x_2, \dots, x_n\}$, 求最后时刻各个隐状态的概率分布, 推测最有可能的观测值 x_{n+1} 。

- 已知模型参数 $\lambda = [A, B, \pi]$ 和某一特定的观测序列，求中间时刻各个隐状态的概率分布，换言之，就是根据观测序列推测隐藏的模型状态。通常使用 viterbi 算法解决，实验一将实现该算法。
- 已知某一特定的观测序列，调整模型参数 $\lambda = [A, B, \pi]$ ，使得该序列出现的概率最大。即，训练模型使其能最好地描述观测数据。通常可以使用极大似然法或是 Baum-Welch 算法，来估计模型参数，在实验二、三将实现 Baum-Welch 算法的关键步骤。

实验一. viterbi 算法

viterbi 算法是一种动态规划算法，它用于寻找最有可能产生观测序列的维特比路径——隐状态序列，特别是在马尔可夫信息源上下文和隐马尔可夫模型中。该算法的伪代码描述如算法 1 所示 [?], 其中输入及输出参数的说明见综述部分, $\delta[i, j]$ 保存在 i 时刻获取到观测状态 s_j 的概率的最大值, $\phi[i, j]$ 用于记录路径。

Algorithm 1 viterbi 算法

Input: O, S, π, X, A, B

Procedure: Y

```

1: for each state  $s_i$  do
2:    $\delta[i, 1] \leftarrow \pi \cdot B_{ix_1}$ 
3:    $\phi[i, 1] \leftarrow 0$ 
4: end for
5: for  $i \leftarrow 2, 3, \dots, T$  do
6:   for each state  $s_j$  do
7:      $\delta[j, i] \leftarrow \max_k (\delta[k, i-1] \cdot A_{kj} \cdot B_{jx_i})$ 
8:      $\phi[j, i] \leftarrow \arg \max_k (\delta[k, i-1] \cdot A_{kj} \cdot B_{jx_i})$ 
9:   end for
10: end for
11:  $Y[T] \leftarrow \arg \max_k (\delta[k, T])$ 
12: for  $i \leftarrow T-1, \dots, 2$  do
13:    $Y[i] \leftarrow \phi[Y[i+1], i+1]$ 
14: end for
15: return  $Y$ 

```

实验二. Forward 算法

前向概率 [?]: 给定隐马尔可夫模型参数 $\lambda = [A, B, \pi]$, 到 t 时刻为止, 观测序列为 o_1, o_2, \dots, o_t 且状态为 s_i 的概率, 记作:

$$\alpha_t(i) = P(o_1, o_2, \dots, o_t, y_t = s_i | \lambda)$$

可以递归求得前向概率 $\alpha_t(i)$, Forward 算法描述如下:

Algorithm 2 Forward 算法

Input: $O, \lambda = [A, B, \pi]$ **Procedure:** α

```
1: for each state  $b_i$  do
2:    $\alpha_1(i) \leftarrow \pi_i b_i(o_1)$ 
3: end for
4: for  $t \leftarrow 2, 3, \dots, T$  do
5:   for each state  $b_i$  do
6:      $\alpha_t(i) = [\sum_{j=1}^N \alpha_{t-1}(j) a_{ji}] b_i(o_t)$ 
7:   end for
8: end for
9: return  $\alpha$ 
```

实验三. Backward 算法

Algorithm 3 Backward 算法

Input: $O, \lambda = [A, B, \pi]$ **Procedure:** β

```
1: for each state  $b_i$  do
2:    $\beta_T(i) \leftarrow 1$ 
3: end for
4: for  $t \leftarrow T-1, T-2, \dots, 1$  do
5:   for each state  $b_i$  do
6:      $\beta_t(i) = [\sum_{j=1}^N \beta_{t+1}(j) a_{ji}] b_i(o_{t+1})$ 
7:   end for
8: end for
9: return  $\beta$ 
```

后向概率 [?]: 给定隐马尔可夫模型参数 $\lambda = [A, B, \pi]$, 在 t 时刻状态为 s_i 的条件下, 从 $t+1$ 时刻到 T 的部分观测序列为 $o_{t+1}, o_{t+2}, \dots, o_T$ 的概率, 记作:

$$\beta_t(i) = P(o_{t+1}, o_{t+2}, \dots, o_T | y_t = s_i, \lambda)$$

可以递归求得前向概率 $\beta_t(i)$, Backward 算法描述如算法 3 所示。

结果

程序运行结果如图 2 所示。

图 2: 运行结果

参考文献